

حل مسئله فروشنده دوره گرد با استفاده از ترکیب الگوریتم های
ازدحام ذرات و شبیه سازی تبریدی



یکی از مسائل مهم در تئوری گراف ها مسئله فروشنده دوره گرد tsp می باشد اکثر مسائلی که میتوان آنها را با مسئله فروشنده دوره گرد مدل کرد دارای مقیاس خیلی بزرگ هستند که الگوریتم های موجود قادر به حل آنها در یک زمان قابل قبول نیستند. در حل مسئله TSP با توجه به اهمیت و کاربرد بسیار زیاد آن در حوزه های مختلف مهندسی به دنبال جایگشتی مناسب از n شهر می باشیم این مسئله به عنوان مسئله NP-Hard شناخته شده است بررسی تمام راه حل ها با افزایش ابعاد مسئله عملاً امکان پذیر نیست و نیاز داریم که از روشهای سریع و کارا مانند روشهای هوش جمعی استفاده کنیم در این تحقیق حل مسئله فروشنده دوره گرد با استفاده از الگوریتم ازدحام جمعیت و شبیه سازی تبریدی ارایه شده است

مقدمه :

مسئله فروشنده دوره گرد به عنوان یکی از مسائل مهم بهینه سازی با کاربردهای زیاد در دنیای واقعی از جمله مسائل مسیریابی و سایل نقلیه، طراحی تولید، زمان سرویس دهی به مشتریان و غیره همواره مورد توجه پژوهشگران قرار گرفته است و الگوریتم های زیادی برای آنالیز عملکرد خود در حل مسائل پیچیده، به حل این مساله در ادبیات موضوع پرداخته اند. هدف از حل این مسئله، پیدا کردن کوتاهترین مسیری است که از مجموعه ای از شهرها (گره ها) عبور کرده، بطوریکه هر شهر فقط یکبار ملاقات شود و سپس به شهر اولیه که از آن حرکت را شروع کرده است، برگردد. چالش اصلی در ارتباط با این مساله تعداد شهرها میباشد و در واقع با افزایش تعداد گره ها و در نتیجه ایجاد زیر تورها، عمل روشهای دقیق بهینه سازی قادر به حل این مساله در زمان منطقی نمی باشند و الگوریتمهای ابتکاری و فراابتکاری راهکارهای جهت رسیدن به جوابهای بهینه و یا قابل قبول در زمان منطقی ارائه میدهند. در مطالعات گذشته روشهای گوناگونی برای حل مساله TSP معرفی شده است که در این میان الگوریتم ژنتیک، بهینه سازی کلونی مورچگان و بهینه سازی ازدحام ذرات بیشترین تعداد مقالات را داشته اند. دو پژوهشگر به نام های رامان و گیل، عملکرد این سه الگوریتم را در حل مساله TSP با یکدیگر مقایسه نموده اند. اما در سال

2019 دو پژوهشگر دیگر به نام های حلیم و اسماعیل در مقاله ای شش الگوریتم فراابتکاری ژنتیک، جستجوی ممنوعه، بهینه سازی کلونی مورچگان، بهینه سازی فیزیولوژی درخت، روش نزدیکترین همسایگی و تبرید تدریجی را از لحاظ دقت، همگرایی و نتایج به دست آمده با یکدیگر مقایسه کردند با توجه به کاربرد فراوان الگوریتم های الهام گرفته شده از طبیعت در حل مسائل بهینه سازی، محققان همواره در حال معرفی الگوریتم های جدید و یا بهبود الگوریتم های بهینه سازی موجود هستند. در این گزارش یک الگوریتم جدید با استفاده از ترکیب دو الگوریتم ازدحام ذرات و شبیه سازی تبریدی معرفی و کارایی آن در حل TSP بررسی میشود.

مساله فروشنده دوره گرد

با در نظر گرفتن گراف وزن دار کامل G ، مساله فروشنده دوره گرد شامل یافتن گراف همیلتونی با کمترین هزینه می باشد. در واقع در این مساله هر جایگشت از گره های گراف یک جواب مساله و یک دور همیلتونی می باشد. فرمول ریاضی این مساله به صورت معادله زیر می باشد :

$$G = (V, E). \text{whereas}$$

$$c: E \rightarrow N \text{ and } V = \{v_1, v_2, \dots, v_n\} \text{ for } n \in N - \{0\}$$

در معادله بالا برای هر ورودی (G, c) ، $M(G, c) = \{v_{i1}, v_{i2}, \dots, v_{in}\}$ است که $\{i1, \dots, in\}$ یک جایگشت از 1 تا n (دور همیلتونی) می باشد. برای هر دور همیلتونی، تابع هدف به صورت کمینه کردن وزنهای یال های گراف به صورت معادله زیر تعریف میشود :

$$H = v_{i1} \cdot v_{i2} \cdot \dots \cdot v_{in} \in M(G, c)$$

$$Cost\{(v_1, v_2, \dots, v_n), (G, c)\} = \sum_{j=1}^n c(v_{ij}, v_{i(j \bmod n)+1})$$

در ادامه ابتدا به تشریح هر کدام از الگوریتم های ازدحام ذرات و شبیه سازی تبریدی پرداخته، و سپس به ساختار پروژه و پیاده سازی مسئله میپردازیم.

در ریاضیات و علوم کامپیوتر، مساله بهینه سازی (Optimization Problem)، در واقع مساله پیدا کردن «بهترین» راه حل، از میان کلیه راه حل های «ممکن» برای مساله است. نوع خاصی از مسائل بهینه سازی وجود دارند که در آنها، به دلیل زیاد شدن تعداد اشیا (Objects) منظور تعداد مشاهدات است، مدیریت کردن آنها با استفاده از روش های ترکیبیاتی (Combinatorial Methods) امکان پذیر نیست. یک مثال شناخته شده از چنین مسائلی، مساله فروشنده دوره گرد (Traveling Salesman Problem) است که از دسته مسائل ان پی کامل (NP-Complete) میباشد.

برای حل چنین مسائلی، یک الگوریتم بسیار کاربردی به نام «شبیه سازی تبرید (Simulated Annealing)» به آن «تبرید شبیه سازی شده»، «بازپخت شبیه سازی شده» و یا به طور خلاصه، SA نیز گفته می شود، وجود دارد. از الگوریتم شبیه سازی تبرید اغلب برای تخمین «بهینه سراسری (Global Optimization)» در مسائل بهینه سازی که فضای جستجوی آنها بزرگ است، استفاده می شود.

همچنین، این الگوریتم معمولاً هنگامی که فضای جستجو گسسته باشد، مورد استفاده قرار می گیرد (همه سفرهایی که از مجموعه مشخصی از شهرها طی آنها عبور می شود). پیش از پرداختن به الگوریتم، مفهوم فرایند بازپخت انیلینگ (Annealing) | در متالورژی (Metallurgy) که الگوریتم تبرید شبیه سازی شده در واقع تقلیدی از آن است، بیان خواهد شد. سپس، الگوریتم شبیه سازی تبرید شرح داده می شود و در نهایت به حل مساله فروشنده دوره گرد با آن پرداخته می شود.

فرایند بازپخت یا انیلینگ

در متالورژی و علم مواد، بازپخت یا انیلینگ، به عملیات حرارتی گفته می‌شود که طی آن مشخصات فیزیکی و گاهی، مشخصات شیمیایی ماده تغییر می‌کند. این کار با هدف افزایش شکل‌پذیری و کاهش سختی ماده انجام می‌شود. طی این فرایند، ابتدا فلز گرم شده، سپس در یک درجه حرارت خاص نگه داشته و در نهایت، به تدریج سرد می‌شود. با گرم کردن فلز، مولکول‌ها آزادانه به هر سوی حرکت می‌کنند. با سرد کردن تدریجی ماده، این آزادی کاهش پیدا می‌کند. اگر فرایند سرد کردن به اندازه کافی کند باشد که بتوان اطمینان حاصل کرد فلز در هر مرحله در تعادل ترمودینامیکی قرار دارد، می‌توان مطمئن شد که انرژی گرمایی به طور یکنواخت در جسم توزیع شده و بهترین ساختار بلوری در آن وجود دارد که متقارن و مقاوم است. در الگوریتم شبیه‌سازی تبرید، از فرایند مذکور الگوبرداری شده است.

مساله فروشنده دوره‌گرد

در مساله «فروشنده دوره‌گرد» (Travelling Salesman Problem | TSP)، پرسش زیر مطرح می‌شود:

لیستی از شهرها و فاصله بین هر جفت از شهرها موجود است. کوتاه‌ترین مسیر ممکن که با استفاده از آن بتوان از یک نقطه شروع کرد و پس از عبور از همه شهرها به نقطه اول بازگشت، کدام است؟


این مساله، یکی از مسائل «ان پی-سخت (NP-Hard)» در بهینه‌سازی کامپیوتری محسوب می‌شود که در حوزه «تحقیق در عملیات (Operational Research | OR)» و «علوم نظری رایانه (Theoretical Computer Science | TCS)» حائز اهمیت است. در نظریه پیچیدگی محاسباتی (Theory of Computational Complexity)، نسخه تصمیم مساله فرو شنده دوره‌گرد که در آن یک طول L داده شده، وظیفه تصمیم‌گیری پیرامون آن است که آیا گراف دارای دوری کمتر از L است یا خیر (از جمله مسائل ان پی-کامل محسوب می‌شود) بنابراین، این امکان وجود دارد که بدترین زمان اجرا برای هر الگوریتم برای TSP، با افزایش تعداد شهرها به صورت «فوق چند جمله‌ای (Superpolynomially)» افزایش پیدا کند (اما نه بیش‌تر از نمایی).

این مساله برای اولین بار در سال ۱۹۳۰ فرموله شد و یکی از مسائلی است که بیشترین مطالعات در حوزه بهینه‌سازی روی آن انجام شده است. از این مساله، به عنوان بنچ‌مارک (Benchmark) برای بسیاری از روش‌های بهینه‌سازی استفاده می‌شود. هرچند حل مساله فرو شنده دوره‌گرد حتی به لحاظ کامپیوتری نیز دشوار است، تعداد زیادی از روش‌های تکاملی (Evolutionary Algorithms) و الگوریتم‌های دقیق (Exact Algorithm) برای حل این مساله شناخته شده هستند که می‌توانند TSP را با تعداد هزاران و حتی میلیون‌ها شهر حل کنند. مساله فرو شنده دوره‌گرد را می‌توان به صورت یک مساله گراف و یا برنامه‌نویسی خطی صحیح (Integer Linear Programming) فرموله کرد. تعداد کل پاسخ‌های ممکن برای مساله برابر با $(n-1)!/2$ برای $n > 2$ است که در آن، n تعداد کل شهرها است. در واقع، این عدد تعداد دورهای همیلتونی در یک گراف کامل با n راس را نشان می‌دهد.

الگوریتم شبیه سازی تبرید

همانطور که پیش‌تر بیان شد، در الگوریتم شبیه سازی تبرید (یا تبرید شبیه سازی شده) از فرایند بازپخت که از مباحث رشته متالورژی و مواد محسوب می‌شود، الگو گرفته شده است. انتخاب نام شبیه سازی تبرید برای این الگوریتم، ریشه در فرایند دارد که از آن تقلید می‌کند. در بهینه‌سازی

نیز مانند فرایند انیلینگ، آنچه در بخش پیشین پیرامون بازپخت مواد بیان شد، برای حل مسائل قابل انجام است. یعنی در واقع، جواب‌های یک مساله به خوبی گرم می‌شوند و با نو سانات زیادی تغییر می‌کنند؛ سپس، به تدریج دامنه تغییرات کم می‌شود و در واقع یک سری شیار به سمت جواب بهینه ساخته می‌شوند. الگوریتم شبیه سازی تبرید برای اولین بار در سال ۱۹۸۳، توسط «کریک‌پاتریک» (Kirkpatrick) «و همکاران معرفی شد. شایان ذکر است، الگوریتم شبیه سازی تبرید از جمله الگوریتم‌های فراابتکاری (فرااکتشافی | Metaheuristic) محسوب می‌شود. در الگوریتم شبیه سازی تبرید، از روش احتمالاتی برای حل مساله بهینه سازی استفاده می‌شود.



در الگوریتم شبیه سازی تبرید (SA)، نقطه s یک حالت از سیستم فیزیکی محسوب می‌شود و تابع $E(s)$ مشابه با انرژی داخلی سیستم در حالت s است. هدف آن است که با شروع سیستم از یک حالت اولیه دلخواه (یک s_0 دلخواه)، به حالتی رسیده شود (s_n) که تابع $E(s)$ در آن کمینه است. در واقع، با شروع از یک حالت دلخواه از سیستم فیزیکی، به حالتی رسیده می‌شود که انرژی داخلی سیستم در آن حالت کمینه است (سیستم کمترین انرژی را در آن حالت خواهد داشت). برای انجام این کار، الگوریتم از یک نقطه دلخواه آغاز به کار و سپس، یک حالت همسایه را انتخاب می‌کند. پس از آن، به طور احتمالی تصمیم می‌گیرد که در حالت کنونی بماند و یا به حالت همسایه جا به جا شود. مجموع این جا به جایی‌های احتمالی، سیستم را به سوی حالتی با انرژی

داخلی کمتر هدایت می‌کند. این کار تا جایی انجام می‌شود که سیستم به یک حالت عقلانی برسد یا اینکه میزان محاسبات، از یک آستانه مشخص بیشتر شود. برای درک بهتر وجه تمایز الگوریتم شبیه سازی تبرید با برخی از دیگر روش‌های ابتکاری مانند تپه‌نوری، مثال زیر قابل توجه است.

مساله فروشنده دوره‌گرد را می‌توان به عنوان مثالی در نظر گرفت که الگوریتم شبیه سازی تبرید در حل آن کاربرد دارد. همانطور که پیش‌تر بیان شد، در این مساله، فروشنده باید از تعداد زیادی از شهرها در حالی عبور کند که مسافت کل پیموده شده کمینه باشد. اگر فروشنده از یک مسیر تصادفی حرکت خود را آغاز کند، بعداً می‌تواند با این امید که در هر تغییر شهر مسافت پیموده شده را کاهش دهد، به ترتیب از کلیه شهرها عبور کند.

چالش اصلی در حل مساله فروشنده دوره‌گرد با استفاده از روشی مانند الگوریتم تپه‌نوردی (Hill Climbing)، از آنجا نشأت می‌گیرد که این الگوریتم با جا به جایی بین همسایه‌ها معمولاً به حالت کمینه می‌رسد و در همان نقطه متوقف می‌شود (در واقع در حالتی که نسبت به دیگر همسایگی‌های برر سی شده کمینه باشد متوقف می‌شود؛ در صورتی که امکان دارد یک کمینه سراسری وجود داشته باشد). در واقع، الگوریتم تپه‌نوردی «کمینه محلی (Local Minimum) را معمولاً به سرعت پیدا می‌کند، اما ممکن است در همان جا متوقف شود و بنابراین از آنجا به کمینه سراسری (Global Minimum) نمی‌رسد. این در حالی است که شبیه سازی تبرید می‌تواند راه حل خیلی خوبی را حتی در حضور «نویز (Noise) برای چنین مساله‌ای پیدا کند.

راهکار الگوریتم شبیه سازی تبرید برای غلبه بر این مشکل و بهبود استراتژی مذکور، استفاده از دو ترفند است. ترفند اول، از الگوریتم متروپولیس (Metropolis Algorithm) گرفته شده که در سال ۱۹۵۳ توسط متروپولیس و همکاران اون کشف شده است. در این الگوریتم، گاهی مسیرهای کوتاه پذیرفته نمی‌شوند، زیرا این عدم پذیرش منجر به آن می‌شود که الگوریتم فضای راه حل ممکن بزرگ‌تری را اکتشاف کند. ترفند دوم، مجدداً با تقلید از فرایند بازپخت فلز و کاهش دما به دمای پایین‌تر اتفاق می‌افتد. پس از آنکه برر سی‌ها و جا به جایی‌های زیادی انجام شد و مشاهده شد که تابع $E(s)$ این تابع در واقع همان تابع هزینه یا Cost Function است به آرامی کاهش

پیدا می‌کند (دما کاهش پیدا می‌کند)، اندازه انجام جا به جایی‌های «بد» کنترل می‌شود. پس از چندین بار کاهش دما به مقدار کم‌تر، فرایند «فرونشانی» (Quench) «با پذیرش جا به جایی‌های خوب به منظور پیدا کردن کمینه محلی تابع هزینه اتفاق می‌افتد. زمان‌بندی‌های بازپخت (Annealing Schedules) متعددی برای کاهش درجه حرارت وجود دارد، اما نتایج به طور کلی خیلی به جزئیات حساس نیستند.

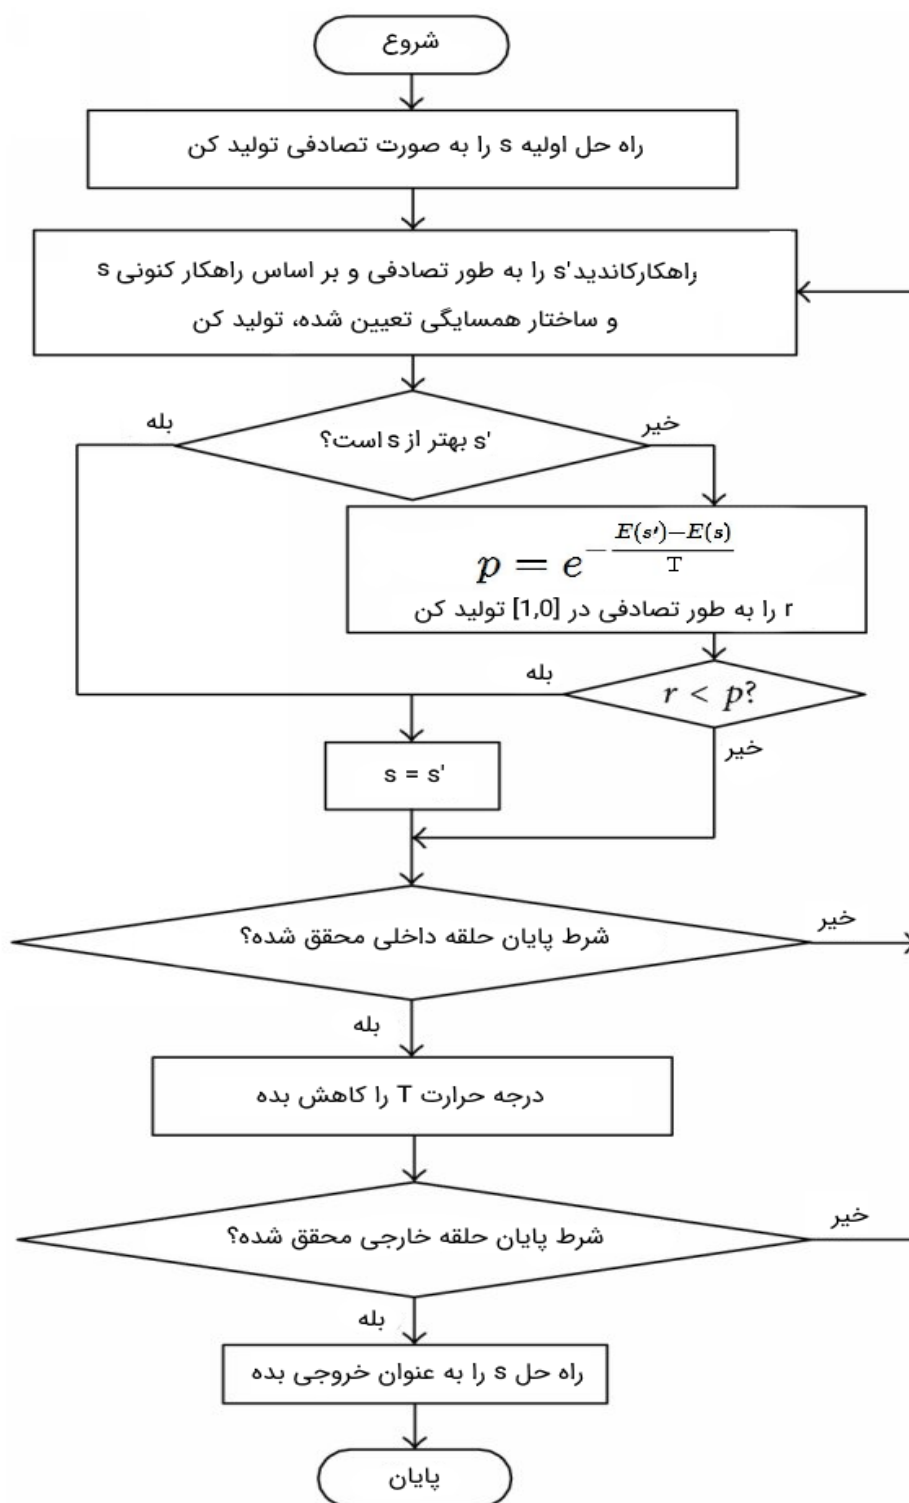
اکنون، الگوریتم شبیه سازی تبرید به صورت ریاضیاتی و دقیق ارائه می‌شود. احتمال انتقال از یک حالت فعلی، مثلاً s به حالت کاندید جدید مانند s' با یک تابع احتمال پذیرش $P(e, e', T)$ مشخص می‌شود که در آن، $e = E(s)$ و $e' = E(s')$ (است) چنانچه پیش‌تر بیان شد، تابع E در فضای حالت نشان‌گر انرژی داخلی سیستم و T نشان‌گر دما است. دمای T بر اساس زمان تغییر می‌کند. بنابراین، با توجه به آنکه پیش‌تر گفته شد هدف آن است که انرژی سیستم کمینه باشد، پس حالتی که منظور s است در آن $E(s)$ کمتر باشد، بهتر از حالتی است که در آن مقدار $E(s)$ بیشتر باشد. نکته قابل توجه در الگوریتم تبرید شبیه سازی شده آن است که تابع احتمال P همواره و حتی در شرایطی که e کوچک‌تر از e' است، باید مثبت باشد. این خصوصیت موجب می‌شود الگوریتم در بهینه محلی که نسبت به بهینه سراسری «بدتر» است، متوقف نشود. در واقع، در صورتی که s' بهتر از s باشد، $E(s) \geq E(s')$ پذیرفته می‌شود و اگر s' بدتر از s باشد و موجب $E(s) < E(s')$ شود، s' با یک احتمال پذیرفته می‌شود. تابع احتمال P به صورت زیر است:

$$p = e^{-\frac{E(s') - E(s)}{T}} = e^{-\frac{\Delta f}{T}}$$

در صورت کاهش دمای T و میل کردن آن به سمت صفر، احتمال P نیز باید کاهش پیدا کند و یا به صفر و یا یک عدد مثبت میل کند. در این شرایط، P هنگامی به سمت صفر میل می‌کند که $e < e'$ باشد و در صورتی که یک عدد مثبت میل می‌کند که $e' < e$ باشد. همانطور که م‌شهود

است، دما در کنترل تغییرات سیستم نقش اساسی دارد. همانطور که پیش‌تر هم بیان شد، دما در شبیه‌سازی به صورت تدریجی کاهش پیدا می‌کند. بنابراین، الگوریتم از $T=\infty$ و به عبارتی، از یک دمای بسیار بزرگ کار خود را آغاز می‌کند و در هر مرحله با توجه به یک زمان‌بندی تبرید از پیش مشخص شده، کاهش پیدا می‌کند. زمان‌بندی تبرید با توجه به این موضوع انجام می‌شود که اگر منابع مورد استفاده (مثلاً میزان محاسبات) به پایان برسند، زمان انجام فرایند نیز به پایان می‌رسد. از همین رو، الگوریتم ابتدا در فضای بزرگی از راه‌حل‌ها، صرف نظر از انرژی داخلی سیستم به دنبال پاسخ می‌گردد و به تدریج، به سمت مناطق دارای انرژی کمتر جا به جا می‌شود. این منطقه، به تدریج کوچک‌تر می‌شود و این کار، تا زمانی که بهینه سراسری یافته شود، ادامه پیدا می‌کند. برای یک مساله دارای فضای متناهی، افزایش زمان موجب می‌شود تا با احتمال یک، الگوریتم در نقطه بهینه سراسری متوقف شود؛ هر چند زمان لازم برای انجام این کار، بیش‌تر از زمان لازم برای جستجو در کل فضا است و بنابراین، این موضوع در عمل کاربردی ندارد.

فلوچارت الگوریتم شبیه سازی تبرید



الگوریتم بهینه سازی ازدحام ذرات (PSO)

در اوایل سال ۱۹۹۰ میلادی، پژوهش‌های گوناگونی پیرامون رفتار اجتماعی گروه‌های حیوانات انجام شد. این پژوهش‌ها حاکی از آن بودند که برخی از حیوانات که به یک گروه خاص متعلق هستند، مانند پرندگان، ماهی‌ها و دیگر موارد، قادر به آن هستند که اطلاعات را در گروه‌های (دسته‌های | گله‌های) خودشان به اشتراک بگذارند و چنین قابلیت‌هایی به این حیوانات مزایای قابل توجهی برای بقا اعطا می‌کرد.

با الهام گرفتن از این مطالعات، «کندی (Kennedy) و ابرهارت (Eberhart) در سال ۱۹۹۵ الگوریتم بهینه سازی ازدحام ذرات (Particle Swarm Optimization | PSO) یا الگوریتم PSO را در یک مقاله معرفی کردند. الگوریتم بهینه سازی ازدحام ذرات یا الگوریتم PSO یک الگوریتم فراابتکاری (Metaheuristic) است که برای بهینه‌سازی توابع پیوسته غیر خطی مناسب محسوب می‌شود. نویسندگان مقاله مذکور، الگوریتم بهینه سازی ازدحام ذرات یا الگوریتم PSO را از مفهوم هوش ذرات (Swarm Intelligence) که معمولاً در گروه‌های حیوانات مانند گله‌ها و دسته‌های حیوانات وجود دارد الهام گرفته و ساخته‌اند.

برای شفاف شدن هر چه بیشتر ساز و کار کلی الگوریتم بهینه سازی ازدحام ذرات و دیگر الگوریتم‌هایی که از رفتار گروهی حیوانات الهام گرفته شده‌اند، توضیحاتی پیرامون رفتار گروهی (گله‌ای) حیوانات ارائه می‌شود. این توضیحات می‌تواند به درک چگونگی ساخت الگوریتم بهینه سازی ازدحام ذرات (و دیگر الگوریتم‌های دارای رویکرد مشابه) برای حل مسائل پیچیده ریاضی کمک کند.

الگوریتم بهینه سازی ازدحام ذرات و رفتار گروهی حیوانات

دسته پرندگانی (گروه پرندگان | ازدحام پرندگان) که بر فراز یک منطقه در حال حرکت هستند، باید یک نقطه را برای فرود پیدا کنند. در این حالت، تعریف اینکه همه پرندگان در کدام نقطه باید فرود بیایند، مسئله پیچیده‌ای است. زیرا پاسخ این مسئله، وابسته به موضوعات مختلفی یعنی پیشینه کردن منابع غذایی در دسترس و کمینه کردن خطر وجود شکارچیان است در نقطه محل

فرود است. در این شرایط، ناظر می‌تواند حرکت پرندگان را به صورت رقص‌پردازی ببیند. پرندگان به طور هم‌زمان در یک برهه از زمان حرکت می‌کنند تا بهترین محل برای فرود آمدن تعیین شود و همه دسته (گروه) به طور هم‌زمان فرود بیایند.

در مثال بیان شده پیرامون حرکت ازدحامی پرندگان و فرود هم‌زمان آن‌ها، اعضای دسته پرندگان (گروه پرندگان) یا همان ازدحام پرندگان، امکان به اشتراک‌گذاری اطلاعات با یکدیگر را دارند. در صورتی که پرندگان امکان به اشتراک‌گذاری اطلاعات با یکدیگر را در گروه‌های خود نشان داده باشند، هر پرنده‌ای از گروه (دسته) در محل (نقطه) و در زمان متفاوتی فرود می‌آید.

پژوهش‌هایی که از سال ۱۹۹۰ پیرامون رفتار پرندگان انجام شد، حاکی از آن است که همه پرندگان یک ازدحام (گروه | دسته) که به دنبال نقطه خوبی برای فرود هستند، قادر به آن هستند که از بهترین نقطه برای فرود در هنگامی که آن نقطه توسط یکی از اعضای ازدحام پیدا شد، آگاه شوند. با استفاده از این آگاهی، هر یک از اعضای این ازدحام، تجربه دانش شخصی و ازدحامی خود را متوازن می‌کنند که با عنوان دانش اجتماعی (Social Knowledge) شناخته شده است.

شایان ذکر است که معیارهایی که برای ارزیابی خوب یا نامناسب بودن یک نقطه برای فرود مورد بررسی قرار می‌گیرند، شرایط بقایی هستند که در یک نقطه، برای بقا وجود خواهند داشت. از جمله این موارد، بیشینه بودن منابع غذایی و کمینه بودن خطر وجود شکارچیان است که پیش‌تر نیز به آن‌ها اشاره شد. مسئله پیدا کردن بهترین نقطه برای فرود، یک مسئله بهینه‌سازی محسوب می‌شود. گروه، ازدحام یا گله باید بهترین نقطه فرود، برای مثال طول و عرض جغرافیایی را، به منظور بیشینه کردن شرایط بقای اعضای خود تعیین کند.

برای انجام این کار، هر پرنده‌ای ضمن پرواز، به جستجوی نقطه مناسب فرود می‌پردازد و نقاط مختلف را از جهت معیارهای بقای گوناگون مورد ارزیابی قرار می‌دهد تا بهترین منطقه برای فرود

را پیدا کند و این کار تا زمانی انجام می‌شود که بهترین منطقه برای فرود، توسط کل ازدحام مشخص شود.

کندی و ابرهاریت، از رفتار جمعی پرندگان الهام گرفتند؛ رفتاری که مزایای بقای قابل توجهی را برای پرندگان در هنگام جستجو برای یک نقطه امن برای فرود تضمین می‌کرد. آن‌ها بر همین اساس، الگوریتمی را ارائه کردند که الگوریتم ازدحام ذرات (Particle Swarm Optimization) نامیده می‌شود. الگوریتم PSO می‌تواند رفتاری به مثابه آنچه برای دسته پرندگان گفته شد را تقلید کند.

الگوریتم بهینه سازی ازدحام ذرات کلاسیک

نسخه اولیه الگوریتم ازدحام ذرات یا الگوریتم PSO که با عنوان نسخه کلاسیک این الگوریتم نیز شناخته شده است، در سال ۱۹۹۵ ارائه شد. از آن زمان تاکنون، انواع دیگری از این الگوریتم به عنوان نسخه‌های دیگر الگوریتم کلاسیک ارائه شده‌اند که از جمله آن‌ها می‌توان به کاهش خطی وزن اینرسی (Linear-Decreasing Inertia Weight)، وزن عامل انقباض (The Constriction Factor Weight) و اینرسی پویا (Dynamic Inertia) در کنار مدل‌های ترکیبی یا حتی روش‌های بهینه سازی الهام گرفته شده از کوانتوم که روی الگوریتم PSO اعمال شده‌اند اشاره کرد. هدف از مسائل بهینه‌سازی، تعیین متغیری است که با بردار $X = [x_1 x_2 x_3 \dots x_n]$ نشان داده می‌شود و بسته به فرمول بهینه‌سازی ارائه شده توسط تابع $f(X)$ ، بیشینه یا کمینه می‌شود. بردار متغیر X ، به عنوان یک بردار مثبت شناخته شده است. این بردار، یک مدل متغیر و بردار n بُعدی آن را نمایش می‌دهد که در آن، n نشانگر تعداد متغیرهایی است که ممکن است در مسئله تعیین شوند n . در مسئله پیدا کردن بهترین نقطه برای فرود دسته پرندگان، طول و عرض جغرافیایی است.

از سوی دیگر، تابع $f(X)$ تابع برازش (Fitness Function) یا تابع هدف (Objective Function) نامیده می‌شود و تابعی است که میزان خوب یا بد بودن یک موقعیت X را ارزیابی می‌کند. این تابع برای مسئله دسته پرندگان، میزان خوب بودن یک نقطه برای فرود است که پرنده پس از پیدا کردن یک نقطه به آن فکر می‌کند. چنین ارزیابی برای مسئله فرود گروه پرندگان، بر اساس معیارهای بقای گوناگون انجام می‌شود. اکنون، ازدحامی با P ذره در نظر گرفته می‌شود؛ یک بردار مکان X_i^t و یک بردار سرعت V_i^t در هر تکرار برای هر یک از i ذره‌ای این سرعت را ایجاد می‌کنند، به صورت زیر وجود دارد:

$$X_i^t = (x_{i1} x_{i2} x_{i3} \dots x_{in})^T$$

$$V_i^t = (v_{i1} v_{i2} v_{i3} \dots v_{in})^T$$

این بردارها بر اساس بُعد j مطابق با معادله‌ای که در ادامه آمده است، به روز رسانی می‌شوند

$$V_{ij}^{t+1} = wV_{ij}^t + c_1 r_1^t (pbest_{ij} - X_{ij}^t) + c_2 r_2^t (gbest_j - X_{ij}^t)$$

و

$$X_{ij}^{t+1} = X_{ij}^t + V_{ij}^{t+1}$$

که در آن‌ها، داریم:

$$i = 1, 2, \dots, P \text{ و } j = 1, 2, \dots, n.$$

معادله اول نشانگر آن است که سه عامل مختلف در حرکت ذرات در یک تکرار، نقش آفرین هستند. بنابراین، سه عبارت در این رابطه وجود دارد که بعداً مورد بررسی قرار خواهند گرفت. در عین حال، معادله دوم، موقعیت ذرات را به روزرسانی می‌کند. پارامتر w ثابت وزن اینرسی است و برای نسخه کلاسیک PSO، این مقدار یک مقدار مثبت ثابت است. در نسخه کلاسیک PSO، مقدار پارامتر w مثبت است. این پارامتر برای متوازن کردن جستجوی سراسری حائز اهمیت است که به آن اکتشاف (هنگامی که مقادیر بالاتری تنظیم شده‌اند) و جستجوی محلی (وقتی مقادیر کمتری تنظیم شده‌اند) نیز گفته می‌شود. یکی از مهم‌ترین تفاوت‌های الگوریتم PSO کلاسیک با دیگر نسخه‌های مشتق شده از این الگوریتم، پارامتر w است. سرعتی که اولین عبارت در معادله را به روزرسانی می‌کند، ضرب داخلی پارامتر w و سرعت پیشین ذره است. به همین دلیل است که حرکت پیشین ذره به حرکت کنونی نمایش داده می‌شود. از همین رو، برای مثال، اگر $w = 1$ بود، حرکت ذره به طور کامل به وسیله حرکت قبلی خودش تحت تاثیر قرار گرفته است؛ بنابراین، ذره ممکن است به حرکت خود در همان جهت ادامه دهد.

از سوی دیگر، اگر $0 \leq w < 1$ ، این تاثیر کاهش پیدا می‌کند و این یعنی ذرات به منطقه دیگری در ناحیه جستجو می‌روند. بنابراین، با توجه به کاهش پارامتر وزن اینرسی، ازدحام (گروه | دسته) ممکن است نواحی بیشتری را در ناحیه جستجو مورد اکتشاف قرار دهد و این یعنی شانس پیدا کردن بهینه سراسری افزایش پیدا می‌کند. اگرچه، در حالاتی که از مقادیر w کم‌تر استفاده می‌شود نیز هزینه‌ای وجود دارد که شبیه‌سازی‌ها را زمان‌برتر خواهد کرد.

عبارت درک فردی که دومین عبارت در معادله یک است، به وسیله تفاضل بین بهترین موقعیت خود ذره، برای مثال $pbest_{ij}(ij)$ و موقعیت کنونی آن X_{tij} محاسبه می‌شود. شایان توجه است که ایده نهفته در پس این ایده آن است که هر چه فعالیت‌ها فاصله بیشتری از موقعیت $pbest_{ij}(ij)$ بگیرند، تفاضل $(pbest_{ij} - X_{tij})$ باید افزایش پیدا کند. بنابراین، این عبارت افزایش پیدا کرده و ذره را به بهترین موقعیت آن جذب می‌کند. پارامتر c_1 که به صورت

حاصل ضرب در این رابطه وجود دارد، یک ثابت مثبت و یک پارامتر شناخت فردی محسوب می شود و به اهمیت تجربیات پیشین خود ذره وزن می دهد.

دیگر پارامتری که ضرب عبارت دوم را شکل می دهد، عبارت $r1$ است. $r1$ یک پارامتر مقدار تصادفی با طیف $[0,1]$ است. این پارامتر تصادفی، نقش مهمی را بازی می کند، زیرا از همگرایی پارامترها ممانعت و بهینه سراسری احتمالی را بیشینه می کند. در نهایت، سومین عبارت مربوط به یادگیری اجتماعی است. به دلیل وجود این پارامتر، همه ذرات در ازدحام قادر به آن هستند که اطلاعات پیرامون بهترین نقطه به دست آمده را صرف نظر از اینکه کدام ذره آن را پیدا کرده است، با یکدیگر به اشتراک بگذارند؛ برای مثال $gbest_{ij}$. فرمت این عبارت نیز درست مانند دومین عبارت است که مربوط به یادگیری فردی می شود. بنابراین، تفاضل $(gbest_{ij} - X(t)_{ij})$ مانند یک جاذبه برای ذرات برای بهترین نقطه تا هنگام پیدا شدن نقطه در تکرار t عمل می کند. به طور مشابه، $c2$ پارامتر یادگیری اجتماعی و وزن آن، اهمیت یادگیری سراسری ذرات است. همچنین، $r2$ نیز نقشی مشابه با $r1$ دارد.

در ادامه، الگوریتم PSO ارائه شده است و افراد ممکن است متوجه منطق بهینه سازی موجود در جستجوهای آن برای کمینه ها شوند و همه بردارهای مکانی که توسط تابع $f(X)$ ارزیابی می شوند. تابع $f(X)$ با عنوان «تابع برازش (Fitness Function) شناخته شده است. در تصاویر زیر نیز به روز رسانی هایی در سرعت ذرات و موقعیت آن در تکرار t با در نظر داشتن مسئله دوبعدی با متغیرهای $x1$ و $x2$ انجام شده است.

1. مقداردهی اولیه

- برای هر i در جمعیت ازدحام با اندازه p
- X_i را به طور تصادفی مقداردهی اولیه کن.
- $V_{i1}, V_{i2}, \dots, V_{in}$ را به طور تصادفی مقداردهی اولیه کن.
- تابع برازش $f(X_i)$ را ارزیابی کن.
- $Pbest_{ij}$ را با یک کپی از X_i مقداردهی اولیه کن.

○ g_{best} را با یک نسخه از X_i با بهترین برآزش مقداردهی اولیه کن.

2. مراحل را تا هنگامی که یک معیار توقف ارضا شود، تکرار کن:


○ برای هر ذره i :

○ V_{ti} و X_{ti} را مطابق با معادلات ۱ و ۲ مقداردهی اولیه کن.


○ تابع برآزش $f(X_{ti})$ را ارزیابی کن.

○ اگر $f(pbest_i) < f(X_{ti})$ $pbest_i \leftarrow X_{ti}$

○ اگر $f(gbest) < f(X_{ti})$ $gbest \leftarrow X_{ti}$ $h'v$



بردار سرعت در تکرار t به صورتی که به وسیله دو مولفه ترکیب شده با ارجاع به یک مسئله دوبُعدی است.



این بردار مکانی در تکرار t به روز رسانی شده، در حالیکه به و سیله دو مولفه با ارجاع به مسئله دویبعی ترکیب شده است.

در مورد روش کار :

گفتیم که الگوریتم PSO از دسته الگوریتم های هوش جمعی میباشد که در آن، یک جمعیت اولیه از جواب ها را داریم که با روش های رندم یا یک الگوریتمی، مقدار دهی اولیه شده اند و با ارسال سیگنال ها به یکدیگر و با اشتراک یک هوش اجتماعی، به جواب بهینه نزدیک میشوند. این الگوریتم از ابتدا هدف آن ، بهینه سازی توابع در فضای پیوسته بوده و و برای مسئله فروشنده دوره گرد که دارای یک فضای گسسته از جواب ها میباشد، باید تغییر کند.

$$\begin{aligned}
 \text{Swap} &\Rightarrow (2, 3, 5, 4, 1) \quad \textcircled{1} \quad n_1 \\
 &\Rightarrow (5, 3, 2, 4, 1) \quad \textcircled{2} \quad n_2 \\
 \underline{\text{Subtract}} &\Rightarrow n_2 - n_1 \Rightarrow \underline{(1, 3), \dots} \\
 \underline{(1, 3), (2, 4)} + \underline{(4, 3)} &\Rightarrow \underline{(1, 3), (2, 4), (4, 3)}
 \end{aligned}$$

همانطور که در شکل بالا نیز نشان داده شده است :

در واقع علمگر swap به این صورت هست که در دنباله، جای دو آیتم را با یکدیگر عوض میکنیم.

عملگر subtract شامل لیستی از swap هایی هست که انجام شده تا x_1 به x_2 تبدیل شود.

علمگر add بین دو دنباله نیز، اجتماع لیست ها میباشد.

در الگوریتم زیر، که مربوط به الگوریتم ازدحام ذرات میباشد،

$$\begin{aligned}
 v^i[t+1] &= w v^i[t] \\
 &+ c_1 r_1 (x^{i, best}[t] - x^i[t]) \\
 &+ c_2 r_2 (x^{gbest}[t] - x^i[t])
 \end{aligned}$$

در واقع این W اضافه شده به این دلیل که V یک حرکت تصادفی هست، یعنی هر چه که جلوتر می‌رویم بهتر است این حرکت تصادفی کمتر شود و حرکت به سمت GBEST و PBEST بهتر شود. پس ما در اینجا یک ترکیبی بین PSO و SA داریم که با یک ضریب دمایی (W)، به مرور زمان، تاثیر این حرکت تصادفی را کمتر می‌کنیم.

```

swap.m  X  +
1  function res = swap(node_sequence, swap)
2  -      temp = node_sequence(swap(1));
3  -      node_sequence(swap(1)) = node_sequence(swap(2));
4  -      node_sequence(swap(2)) = temp;
5  -      res = node_sequence;
6  -      clear temp;
7  -  end
8

```

در فایل بالا، عملکرد swap تعریف شده که یک دنباله به این تابع داده می‌شود (که یک ماتریس 1×2 می‌باشد) و دو ایندکس مشخص شده از این دنباله را با یکدیگر جابجا می‌کند.

```

subtract.m  X  +
1  function res = subtract(node_sequence1, node_sequence2)
2  -      res = [];
3  -      for i=1:length(node_sequence1)
4  -          for j=i:length(node_sequence1)
5  -              if node_sequence2(i) == node_sequence1(j) && i ~= j
6  -                  res = [res, [i; j]];
7  -                  node_sequence1 = swap(node_sequence1, res(:, end));
8  -              end
9  -          end
10 -      end
11 -  end

```

و در کد بالا، تابع `subtract` را میبینیم. که با استفاده از دو حلقه `for` تو در تو، دو دنباله را میگیرد و `swap` های مورد نیاز را پیدا میکند و در لیستی به نام `res` ذخیره میکند و این لیست را برمیگرداند.

```
TSPcostFunction.m  ✕  +
1  function cost = TSPcostFunction(node_sequence, node_positions)
2      cost = 0;
3      for i = 1:length(node_sequence) - 1
4          cost = cost + measureDist(node_positions(node_sequence(i), :), ...
5                                     node_positions(node_sequence(i + 1), :));
6      end
7
8  end
9
10 function dist = measureDist(a, b)
11     dist = sqrt((a(1) - b(1))^2 + (a(2) - b(2))^2);
12 end
```

در فایل بالا نیز، تابع `cost` دیده میشود که معیار مسئله ما میباشد که با استفاده از یک تابع به نام `measuredist` که برای اندازه گیری فاصله دو شهر میباشد، فاصله شهرهای متوالی را که در داخل دنباله مشخص شده، اندازه میگیرد و با هم جمع میزند و به عنوان هزینه برمیگرداند و ما به این وسیله، یک ارزش گزاری برای آن `particle` که یک دنباله دارد، مشخص میکنیم.

```
usage.m  ✕  +
1 -  clc;
2 -  clear;
3 -  close all;
4
5 -  program.citiesNumber = 15;
6 -  program.PositionRange = [0 100];
7
8 -  params.MaxIt = 50;
9 -  params.nPop = 20;
10 -  params.showPlot = 1;
11 -  params.showIters = 1;
12  % program
13  % params
14
15 -  out = pso(program, params);
16 -  figure;
17 -  plot(out.BestCost, 'LineWidth', 2)
18  % xlabel('iteration');
19  % ylabel('BestCost');
20
```

در فایل بالا نیز یک مثال استفاده از الگوریتم نوشته شده است که همانطور که دیده میشود متغیرهای تعداد شهرها، موقعیت جغرافیایی شهرها، و همچنین پارامترهای مسئله مانند تعداد کل گردش هایی که مسئله ما باید انجام بدهد و تعداد جمعیت نیز در این فایل تنظیم میشود. و پارامتر دیگری به نام `showplot` که میخواهیم در هر مرحله، موقعیت شهرها در یک گراف به ما نشان داده شود و پارامتر `showiters` که اطلاعات هر دوره گردش را برای ما چاپ میکند را با مقدار 1 مشخص کرده ام که به این معنی است این دو متغیر به همراه `best cost` را نیز در هر مرحله برای ما چاپ میکند.

در فایل `pso.md` نیز که الگوریتم ازدحام نوشته شده است. که تابع اصلی ما تابع `pso` میباشد که مسئله و پارامترها را میگیرد و یکسری پارامترها نیز داخل همین تابع مشخص میشود. در واقع پارامترهای زیر در داخل این فایل مشخص میشود :

```
% PSO Parameters
w = .9;
wdamp = .95;
alpha = .85; % Personal Learning Coefficient
beta = .85; % Global Learning Coefficient
```

پارامتر wdamp همان پارامتری است که در واقع الگوریتم های pso را با SA ترکیب میکند. در واقع در هر تکرار، مقدار wdamp در w ضرب میشود و مقدار حاصل به عنوان W جدید به مسئله داده میشود.

سپس به بخش initialization مسئله میرسیم که ساختار کلی particle ها را مشخص میکنیم که به صورت زیر میباشد .

```
%% Initialization

empty_particle.citySequence = [];
empty_particle.Cost = [];
empty_particle.Velocity = [];
empty_particle.Best.citySequence = [];
empty_particle.Best.Cost = [];

particle = repmat(empty_particle, nPop, 1);

GlobalBest.Cost = inf;

% initialize city positions
cityPositions = unifrnd(PositionMin, PositionMax, PositionSize);

% initialize city positions (for test porpuse with 15 cities and PosiotionRange of 0 100)
```

که یک رشته از توالی شهرها، هزینه آن ها، وکتور سرعت و یک ذره best هم خواهند داشت که نشان دهنده بهترین حالتی است که آن ذره در طول مسیر الگوریتم مشاهده کرده.

در کد، مقدار اولیه globalbest را نیز بی نهایت میگذاریم، به این دلیل که مسئله بهینه سازی ما، هدفش یافتن مینیمم هست و این یعنی اولین باری که الگوریتم شروع به کار میکند، اولین ذره

ای که بیاید، با هر مقدار خطایی، انتخاب میشود. به این دلیل که هر مقداری که داشته باشد از مقدار بینهایت کمتر است.

اگر مسئله ما ماکزیمم میبود، باید این مقدار را منفی بینهایت می گذاشتیم. در نهایت با تابع `unifrnd` یک مقدار اولیه برای موقعیت شهرها در نظر میگیریم که در بازه `positionmin` و `positionmax` این اعداد را تولید میکند. که به عنوان مثال یک مورد را در کد قرار داده ام.

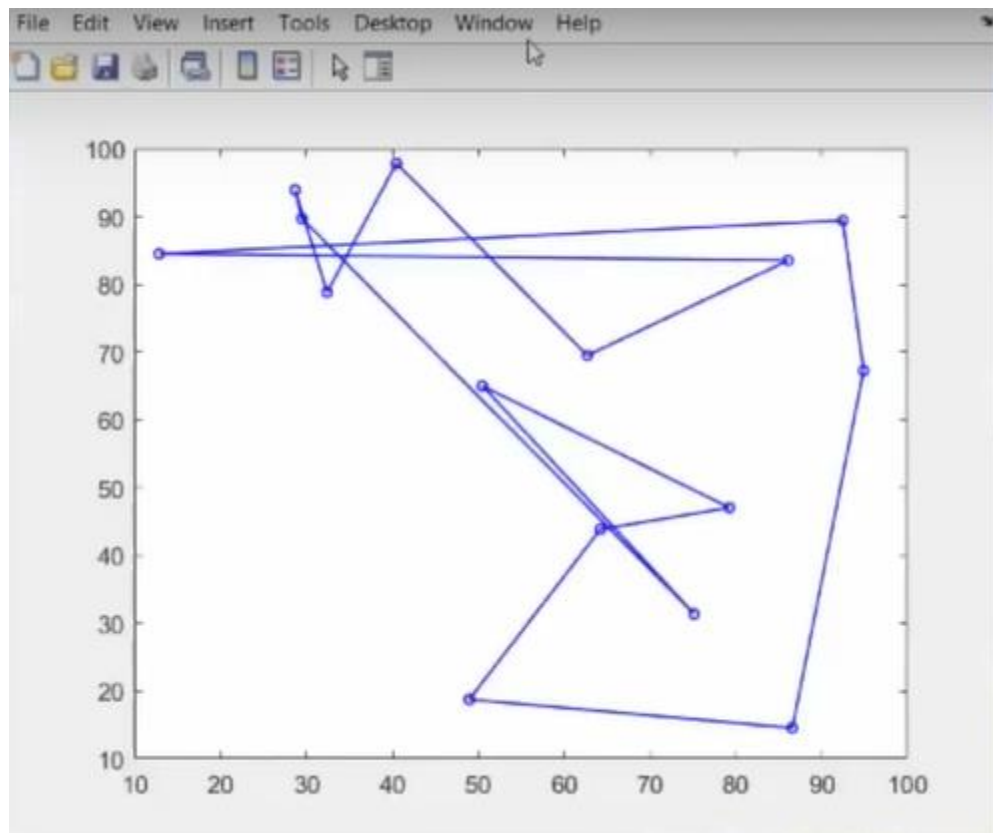
```
% initialize city positions (for test porpuse with 15 cities and PosiotionRange of 0 100)
cityPositions = [
    9.5297    47.2452;
    58.4346    91.4046;
    39.8273    47.2617;
    96.5833    40.5779;
    11.8282    60.6019;
    13.0960    10.6280;
    20.5225    77.0525;
    93.3953    77.1152;
    60.8161    82.1863;
    83.0912    59.4440;
    95.1951     6.8667;
    73.4111    34.8132;
     9.1560    88.5590;
     2.6903    86.0422;
    69.6881    12.0456;
];
```

سپس یک مقدار اولیه برای سایر پارامترهای مسئله قرار میدهم.

```
for i = 1:nPop
    % Initialize city sequence
    particle(i).citySequence = randperm(citiesNumber);

    % Initialize Velocity
    particle(i).Velocity = randi(citiesNumber, [2, ceil(citiesNumber/2)]);
```

در نهایت با اجرا کردن فایل `usage.m` ، چند تا از خروجی های کد را در این جا مشاهده میکنید




```
Command Window  
Iteration 1: Best Cost = 537.4791  
Iteration 2: Best Cost = 537.4791  
Iteration 3: Best Cost = 537.4791  
fx
```

و به همین صورت کد در حال اجرا، ادامه پیدا میکند

```
Command Window
Iteration 1: Best Cost = 537.4791
Iteration 2: Best Cost = 537.4791
Iteration 3: Best Cost = 537.4791
Iteration 4: Best Cost = 537.4791
Iteration 5: Best Cost = 537.4791
Iteration 6: Best Cost = 511.0391
Iteration 7: Best Cost = 511.0391
Iteration 8: Best Cost = 511.0391
Iteration 9: Best Cost = 511.0391
Iteration 10: Best Cost = 511.0391
Iteration 11: Best Cost = 511.0391
Iteration 12: Best Cost = 511.0391
Iteration 13: Best Cost = 511.0391
Iteration 14: Best Cost = 511.0391
Iteration 15: Best Cost = 511.0391
Iteration 16: Best Cost = 511.0391
Iteration 17: Best Cost = 511.0391
Iteration 18: Best Cost = 511.0391
Iteration 19: Best Cost = 511.0391
Iteration 20: Best Cost = 511.0391
Iteration 21: Best Cost = 511.0391
Iteration 22: Best Cost = 511.0391
Iteration 23: Best Cost = 511.0391
Iteration 24: Best Cost = 511.0391
```

تا زمانی که iteration های ما به 50 برسد

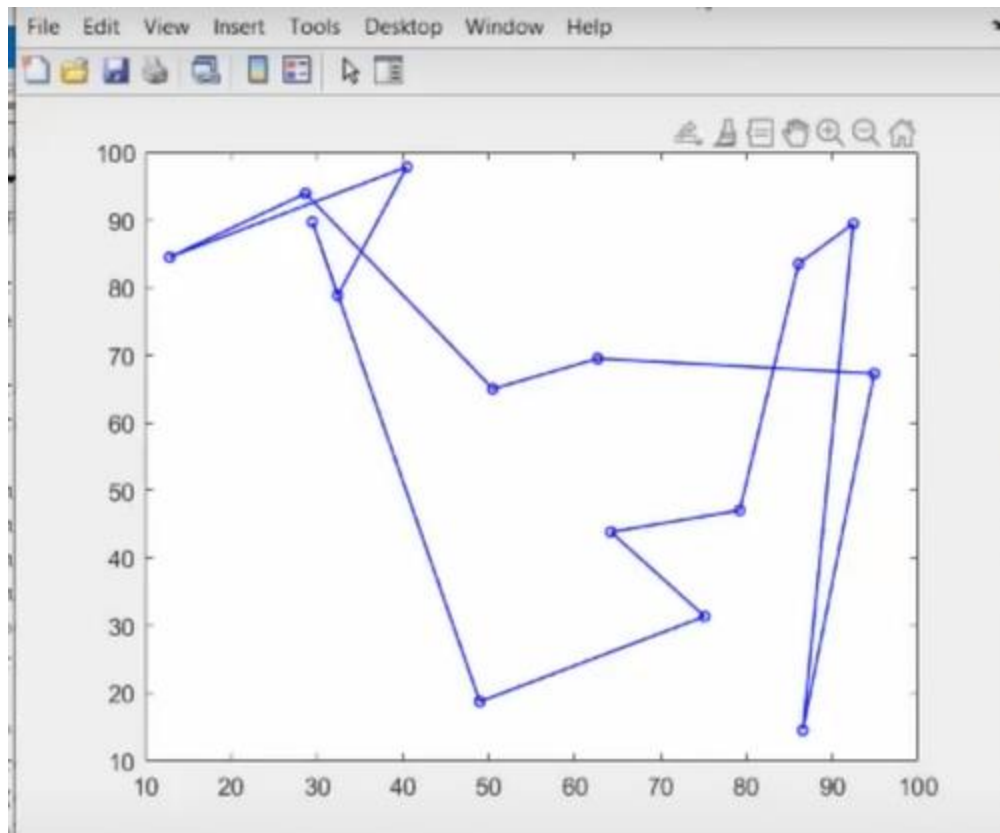
و هر بار که مقدار بهتری به عنوان global best پیدا میکند، این مقدار را در نمودار ترسیم میکند



و در واقع مشاهده میکنیم که به مقدار بهینه نزدیک و نزدیک تر میشود.

```
Iteration 45: Best Cost = 397.7646
Iteration 46: Best Cost = 397.7646
Iteration 47: Best Cost = 397.7646
Iteration 48: Best Cost = 397.7646
```

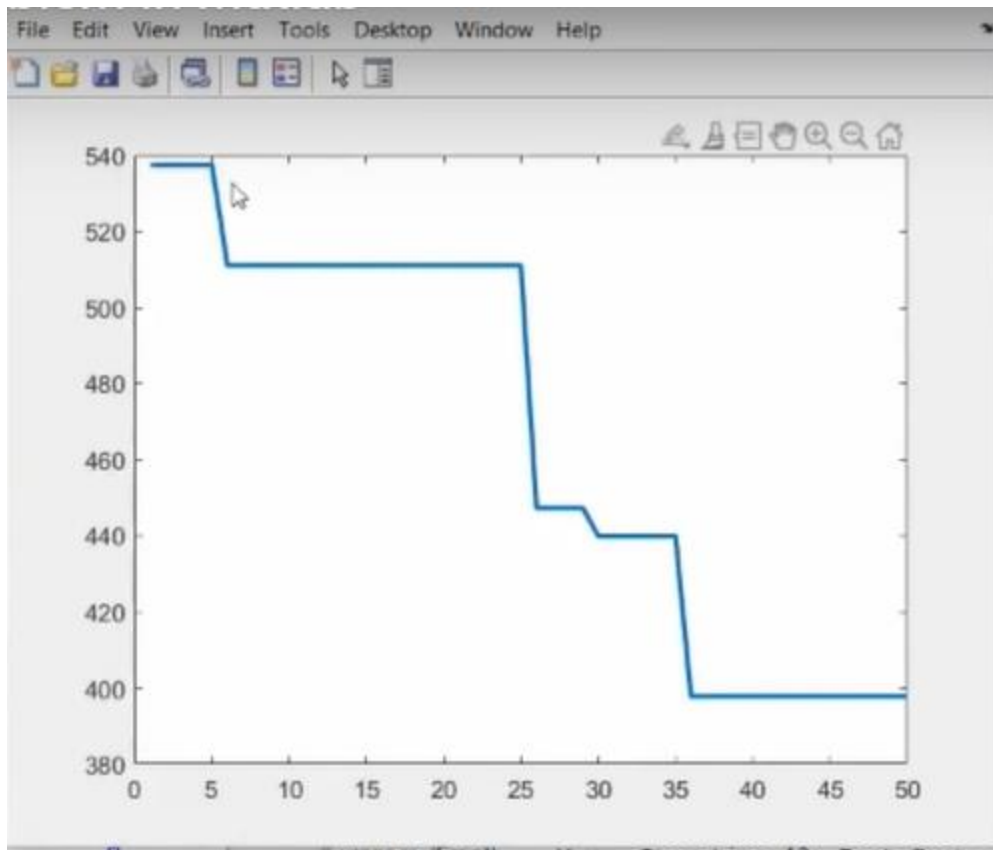
f_1



در واقع بهترین مقدار ما مقدار 397.7646 می باشد

Iteration 50: Best Cost = 397.7646

و تابع نزولی ارزش بهترین particle ما و یا global best ما به صورت زیر می باشد



و در نهایت مقاله ای که در ساخت این پروژه به من کمک کرد و ایده ی اولیه را از آن گرفتم، از لینک زیر قابل دانلود می باشد.

[Solving City Routing Issue with Particle Swarm Optimization](#)

با تشکر